

AULA 7: APRENDIZADO DE MÁQUINAS

MODELOS DE CLASSIFICAÇÃO

INTRODUÇÃO A CIÊNCIA DE DADOS NA ENGENHARIA DE PETRÓLEO

Calendário

DATA	ATIVIDADE
26/08	Introdução
02/09	Tipos de dados/ Pré-processamento
09/09	Aula Prática 1
16/09	Aula Prática 2
23/09	Aula Prática 3
30/09	Introdução ML
07/10	ML Classificação
14/10	Aula Prática 4
21/10	ML Regressão/ML Agrupamento
28/10	Feriado
04/11	Aula Prática 5
11/11	Entrega dos Trabalhos

Tópicos

3


- Classificação
- Classificadores Probabilísticos
 - ▣ Classificador Bayesiano
 - ▣ Regressão Logística
- Máquinas de Suporte de Vetores (Support Vector Machines – SVM)
- Aprendizado baseado em instâncias
 - ▣ KNN
- Métricas de Avaliação

Classificação

4


- Modelo capaz de realizar estimativa do valor da variável de saída discreta a partir das variáveis de entrada.

Conjunto de Treinamento



Margem de
Decisão

Superfície de Decisão




Classificação


5

- Diferentes algoritmos de classificação irão retornar diferentes resultados, de acordo com REPRESENTAÇÃO, FUNÇÃO DE AVALIAÇÃO E OTIMIZAÇÃO.


Conjunto de Treinamento




Regressão Logística




KNN



Árvore de Decisão



SVM

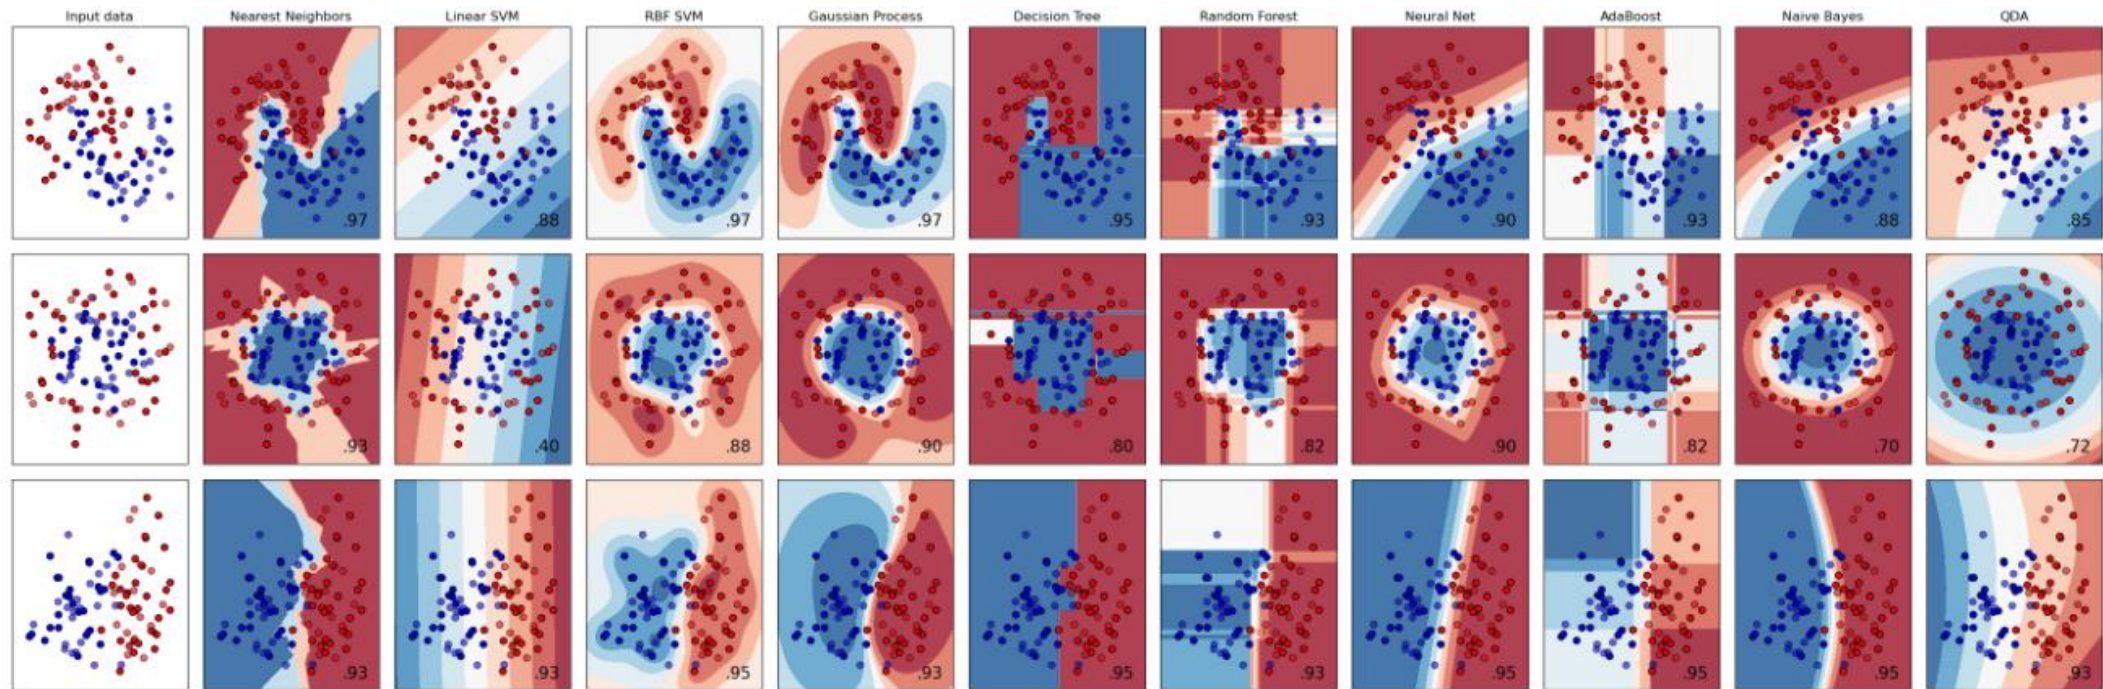


Como achar o melhor modelo e otimizar seus parâmetros?

Classificação

6

- Diferentes algoritmos de classificação irão retornar diferentes resultados, de acordo com REPRESENTAÇÃO, FUNÇÃO DE AVALIAÇÃO E OTIMIZAÇÃO.




https://scikit-learn.org/stable/auto_examples/classification/plot_classifier_comparison.html

Modelos Supervisionados

Classificação

7

- Quando existe uma função que separa as classes no domínio das variáveis, o problema é dito **SEPARÁVEL**, caso contrário o problema é **NÃO SEPARÁVEL**.



Classificadores

8

- Classificadores Probabilísticos:

- *Naive Bayes*

- Regressão Logística

- Máquinas de Suporte de Vetores (Support Vector Machines – SVM)

- Aprendizado baseado em instâncias:

- KNN

Teorema de Bayes

$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)}$$

Teorema de Bayes

$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)}$$

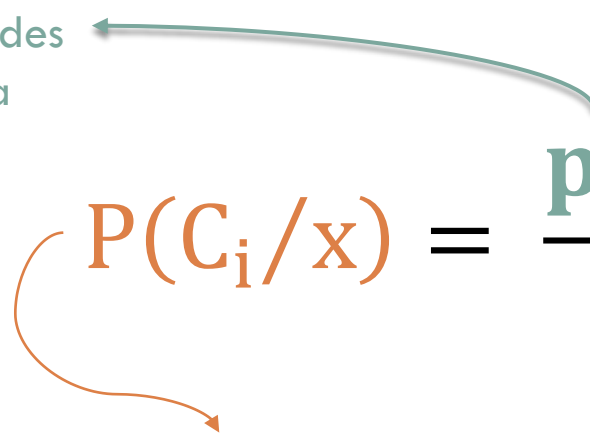
Probabilidade a posteriori :

Probabilidade de observar a classe C_i conhecendo os valores de X .

Teorema de Bayes

**Distribuição da
Probabilidade condicional:**

Distribuição de probabilidades
das variáveis x quando a
classe observada é C_i .


$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)}$$

**Probabilidade a
posteriori :**

Probabilidade de observar
a classe C_i conhecendo os
valores de X .

Classificador Bayesiano

12

Teorema de Bayes

Distribuição da Probabilidade condicional:
Distribuição de probabilidades das variáveis x quando a classe observada é C_i .

$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)}$$

Probabilidade a posteriori :
Probabilidade de observar a classe C_i conhecendo os valores de X .

Probabilidade a priori:
Probabilidade de ocorrência da classe C_i na ausência de qualquer observação.

Classificador Bayesiano

13

Teorema de Bayes

Distribuição da Probabilidade condicional:
Distribuição de probabilidades das variáveis x quando a classe observada é C_i .

$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)}$$

Probabilidade a posteriori :
Probabilidade de observar a classe C_i conhecendo os valores de X .

Probabilidade a priori:
Probabilidade de ocorrência da classe C_i na ausência de qualquer observação.

Densidade de Probabilidade:
Probabilidade de observar valores das variáveis x . Funciona como um fator de padronização para que o resultado permaneça no intervalo de $[0,1]$.

$$p(x) = \sum_{i=1}^m p(x/C_i) P(C_i)$$

Classificador Bayesiano

14

- O que queremos?

$$P(C_i/x_1, x_2, \dots, x_n)$$

Probabilidade a posteriori para cada classe i

- O que precisamos calcular?

$$P(C_i/x) = \frac{p(x/C_i) P(C_i)}{p(x)} \propto p(x/C_i) P(C_i) = p(C_i, x_1, x_2, \dots, x_n)$$

Probabilidade conjunta

- Como se resolve?

$$p(C_i, x_1, x_2, \dots, x_n) = p(x_1/x_2, \dots, x_n, C_i) \cdot p(x_2/x_1, \dots, x_n, C_i) \cdot p(x_3/x_1, \dots, x_n, C_i) \dots$$

Complexo, requer muitos registros com todas essas diferentes condições!

Naive Bayes (Classificador Bayesiano Simples)

15

- O que o algoritmo Naive Bayes assume?

Assume que todas as variáveis são mutualmente independentes, assim conseguimos reduzir o problema, pois:

$$p(x/C_i) = p(x_1/C_i) \cdot p(x_2/C_i) \cdot p(x_3/C_i) \cdot p(x_n/C_i)$$

- Fórmula algoritmo Naive Bayes:

$$P(C_i/x_1, x_2, \dots, x_n) = P(C_i) \cdot P(x_1, x_2, \dots, x_d/c_i) = P(C_i) \cdot \prod_{j=1}^d P(x_j/c_i)$$

↓
Produtório


Naive Bayes

Exemplo

16

Conjunto de Treinamento

X1	X2	y
-5.9	4.6	0
-5.8	-3.2	1
7.4	6.8	0
-8.0	-0.9	1
-14.7	-3.6	1
-14.3	-6.6	1
-11.3	-3.3	1
-11.3	-1.8	1
...



Naive Bayes:

- $P(C_0/x_1, x_2) = P(C_0) \cdot P(x_1/c_0) \cdot P(x_2/c_0)$
- $P(C_1/x_1, x_2) = P(C_1) \cdot P(x_1/c_1) \cdot P(x_2/c_1)$

Conjunto	Quantidade
Classe 0	500
Classe 1	500
Total	1000

Cálculo da Probabilidade a Priori C_i :

$$P(C_0) = \frac{500}{1000} = 0,5$$

$$P(C_1) = \frac{500}{1000} = 0,5$$

Naive Bayes

Exemplo

Conjunto de Treinamento

X1	X2	y
-5.9	4.6	0
-5.8	-3.2	1
7.4	6.8	0
-8.0	-0.9	1
-14.7	-3.6	1
-14.3	-6.6	1
-11.3	-3.3	1
-11.3	-1.8	1
...

$$P(C_0) = 0,5$$

$$P(C_1) = 0,5$$

$P(x_k/c_0)$

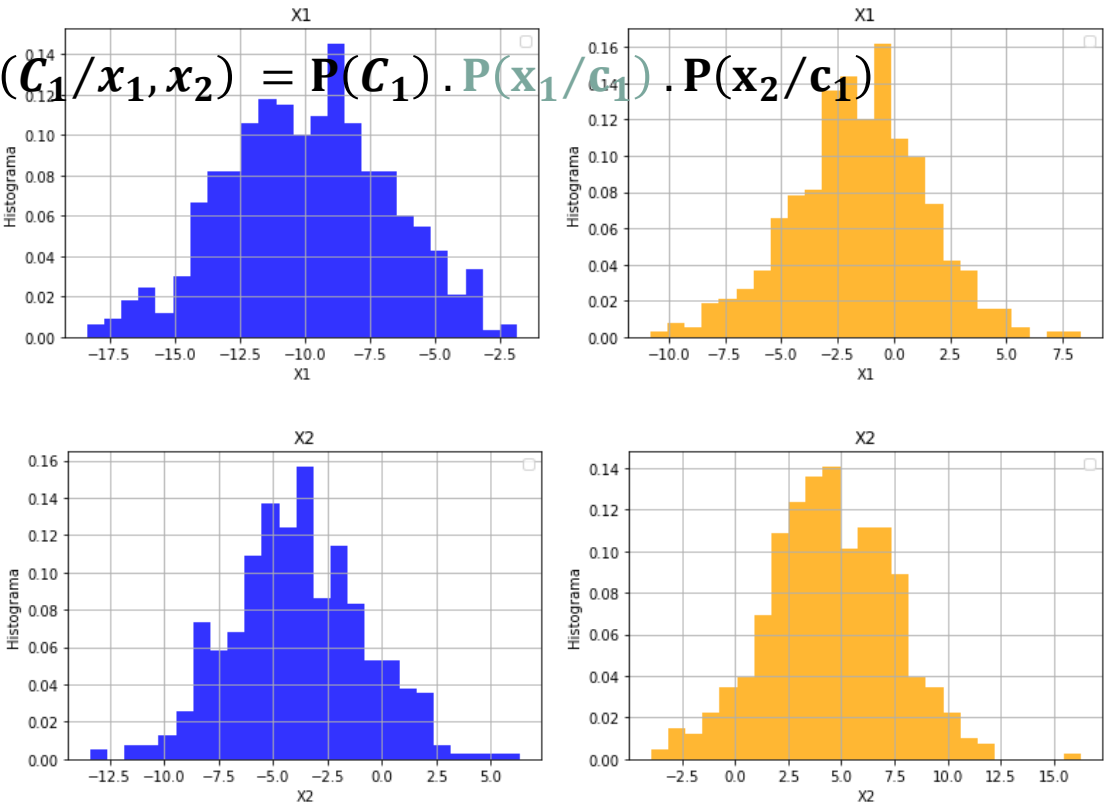
X1	X2	y
-5.9	4.7	0
7.4	6.9	0
1.5	1.7	0
-3.7	5.5	0
0.1	5.4	0
...

$P(x_k/c_1)$

X1	X2	y
-5.8	-3.3	1
-8.0	-1.0	1
-14.7	-3.7	1
-14.3	-6.7	1
-11.3	-3.4	1
...

Cálculo da Distribuição da Probabilidade condicional $P(x_k/c_i)$:

- $P(C_0/x_1, x_2) = P(C_0) \cdot P(x_1/c_0) \cdot P(x_2/c_0)$
- $P(C_1/x_1, x_2) = P(C_1) \cdot P(x_1/c_1) \cdot P(x_2/c_1)$




Qual a distribuição dessas variáveis?

Naive Bayes


Exemplo

Cálculo da Distribuição da Probabilidade condicional $P(x_k/c_i)$:

Geralmente se considera $P(x_k/c_i)$ como uma distribuição Normal (Gaussiana) e se chama de Naive Bayes Gaussiano



Conjunto	Média	SD
Classe 0	-1,5	2,9
Classe 1	-9,9	3,1



Conjunto	Média	SD
Classe 0	4,5	3,0
Classe 1	- 3,9	3,0

Naive Bayes

Exemplo

- Imagine que queremos prever qual classe um novo X

X1	X2	y
-13	10	?

- Resposta:

- $P(C_0/x_1, x_2) = P(C_0) \cdot P(x_1 = -13/c_0) \cdot P(x_2 = 10/c_0)$
- $P(C_1/x_1, x_2) = P(C_1) \cdot P(x_1 = -13/c_1) \cdot P(x_2 = 10/c_1)$

$$P(C_0) = 0,5$$



$$P(C_1) = 0,5$$

- $P(x_1 = -13/c_0) = 6 \times 10^{-5}$

- $P(x_1 = -13/c_1) = 0,08$

- $P(x_2 = 10/c_0) = 0,02$

- $P(x_2 = 10/c_1) = 4 \times 10^{-6}$



Naive Bayes

Exemplo

- Imagine que queremos prever qual classe um novo X

X1	X2	y
-13	10	?

- Resposta:

- $P(C_0/x_1, x_2) = P(C_0) \cdot P(x_1 = -13/c_0) \cdot P(x_2 = 10/c_0) = 0,5 \times 6 \times 10^{-5} \times 0,02 = 7,4 \times 10^{-7}$
- $P(C_1/x_1, x_2) = P(C_1) \cdot P(x_1 = -13/c_1) \cdot P(x_2 = 10/c_1) = 0,5 \times 0,08 \times 4 \times 10^{-6} = 1,6 \times 10^{-7}$

$$P(C_0/x_1 = -13, x_2 = 10) > P(C_1/x_1 = -13, x_2 = 10)$$

Resposta: Y = Classe 0

$$P(C_0) = 0,5$$

$$P(C_1) = 0,5$$

- $P(x_1 = -13/c_0) = 6 \times 10^{-5}$

- $P(x_1 = -13/c_1) = 0,08$

- $P(x_2 = 10/c_0) = 0,02$

- $P(x_2 = 10/c_1) = 4 \times 10^{-6}$


Regressão Logística

21

- Caso especial da regressão linear.

Função Sigmoid


$$p = \frac{1}{1 + e^{-y}}$$



$$p = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x_1 + \dots + \theta_n x_n)}}$$


Probabilidade de ocorrência de um evento binário utilizando uma função logit (curva S).

Regressão Logística



Duas Classes


Regressão Linear



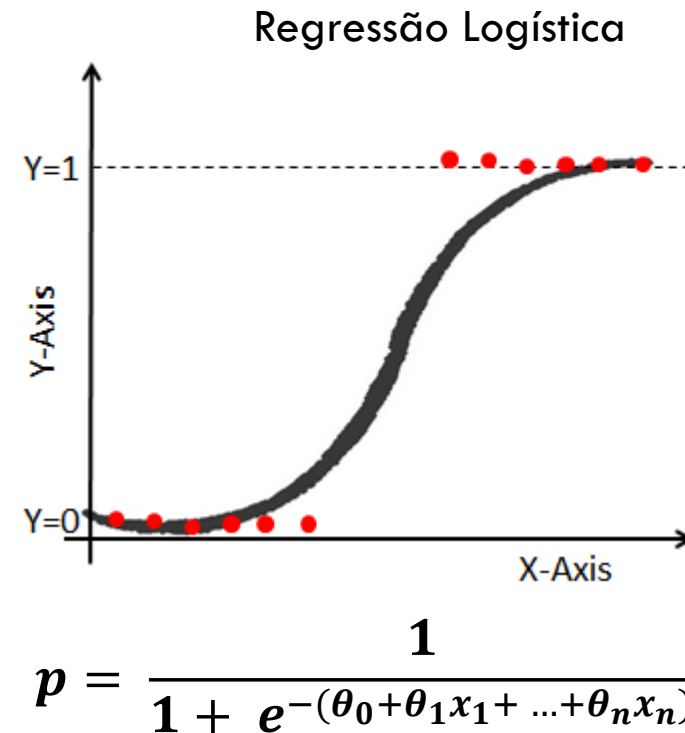
$$y = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

Regressão Logística

22



Função de Otimização:
Método dos Mínimos Quadrados




Função de Otimização:
Método da Máxima Verossimilhança

SVM – Máquinas de Vetores de Suporte

23

- Hiperplano que **maximiza a margem de separação** entre as classes.
- Dados linearmente separáveis:
 - ▣ Hiperplano separa perfeitamente duas classes.
 - ▣ **Margem do hiperplano** : soma de sua distância com os pontos de treinamento mais próximos de cada uma das classes, chamados vetores de suporte.




SVM – Máquinas de Vetores de Suporte

24

□ Dados não perfeitamente linearmente

separáveis:

- Maior parte dos dados estão nos lados corretos dos hiperplanos.
- **Suavização da margem:** Aceitar violação das restrições de margem com uma certa penalidade.
- **Variável de folga:** nível de violação de cada registro.
- **Parâmetro de regularização C:** penaliza essas variações
 - Valores pequenos de C: margens relaxadas
 - Valores grandes de C: margens estreitas



SVM – Máquinas de Vetores de Suporte

25

□ Dados não linearmente separáveis:


□ Nenhum hiperplano linear consegue separar as classes.

□ Mapeamento não linear:

■ Transforma dados originais em uma dimensão maior, e então procuram um hiperplano ótimo que melhor separe as classes.

■ **Truque de Kernel:** Funções de núcleo capazes de aprender os limites de decisão sem realizar explicitamente o mapeamento.

■ Núcleo Linear, Polinomial, **Radial**

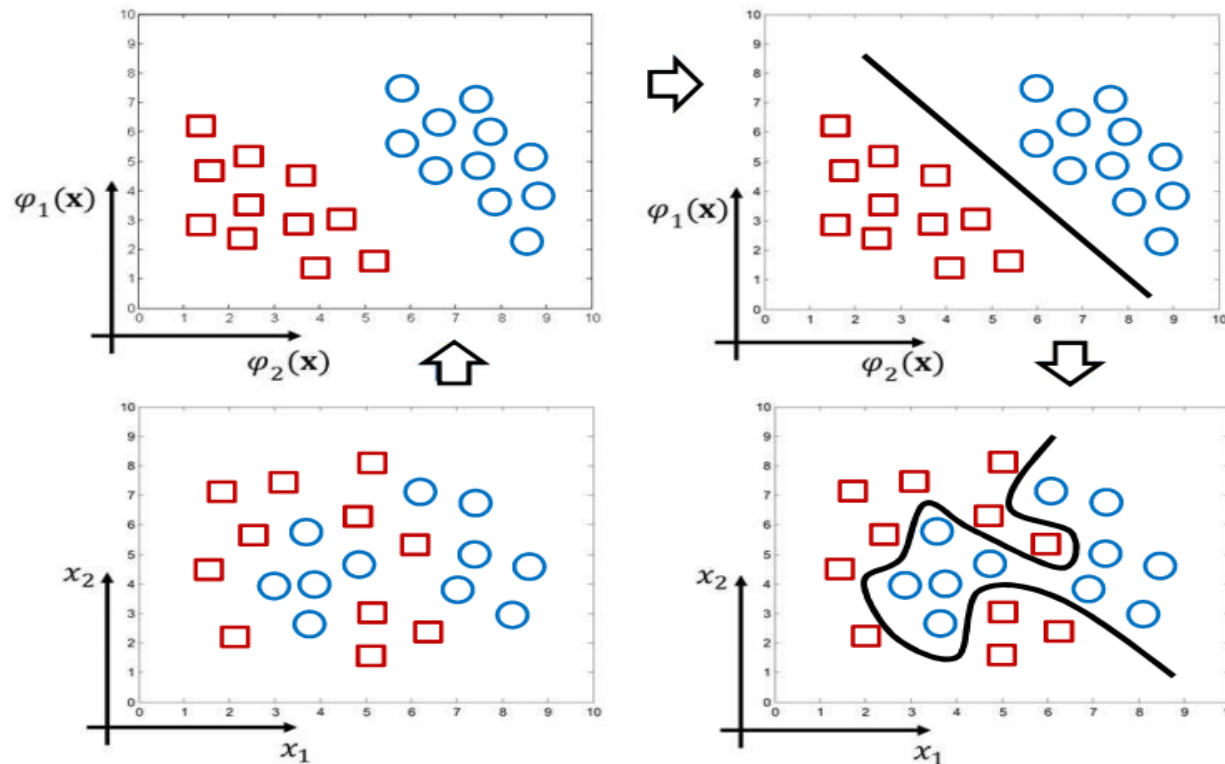


<https://www.hackerearth.com/blog/developers/simple-tutorial-svm-parameter-tuning-python-r/>

SVM – Máquinas de Vetor Suporte

26

- Método não linear que mapeia as variáveis de entrada do problema em um espaço de características de maior dimensão.



KNN (K-vizinhos mais próximos)

27

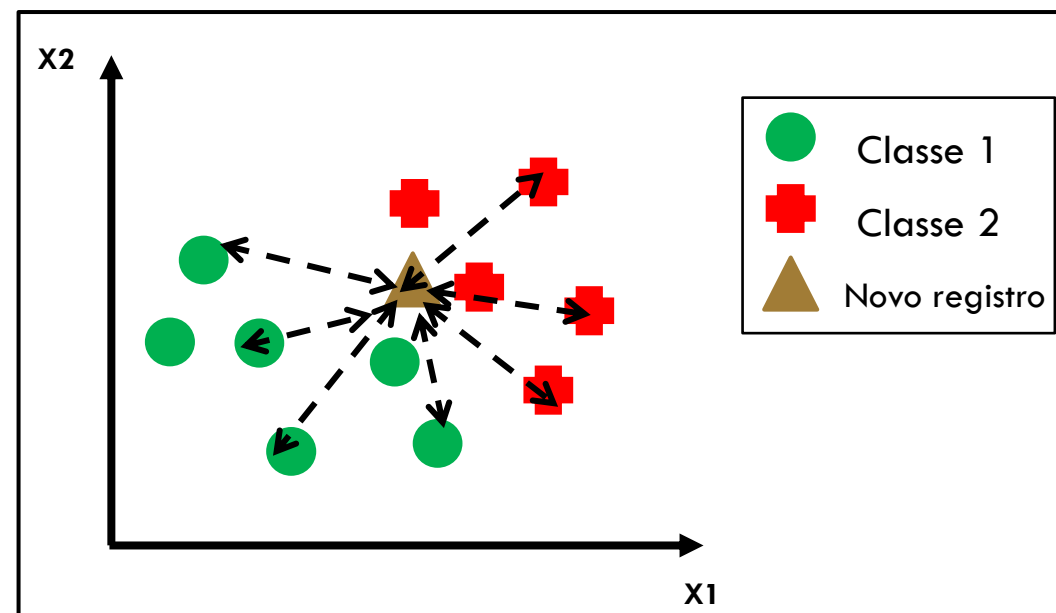
- No KNN, a classe de um determinado registro é a classe mais frequente naqueles k-vizinhos mais próximos.

1. Calcular a distância entre os registros e o novo dado que quer ser classificado.

$$d_{x,y} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Distância Euclidiana

$$d_{i,n} = \sqrt{(x_{i,1} - x_{n,1})^2 + (x_{i,2} - x_{n,2})^2}$$




KNN (K-vizinhos mais próximos)

28

2. Identificar os K vizinhos mais próximos do novo registro.
3. Observação é atribuída ao grupo ao qual a maioria dos K-vizinhos mais próximos estão contidos

Número de Vizinhos	Classificação
3	Classe 2



Avaliação dos Classificadores

29

□ Matriz de Confusão

Previsão

Real

	Classe 1 - Previsão	Classe 2 - Previsão
Classe 1 - Real	VP	FN
Classe 2 - Real	FP	VN

- **Verdadeiros Positivos (VP)** - Número de registros da classe 1 corretamente classificados como classe 1.
- **Verdadeiros Negativos (VN)** - Número de registros da classe 2 corretamente classificados como classe 2.
- **Falsos Negativos (FN)** - Número de registros da classe 1 incorretamente classificados como classe 2.
- **Falsos Positivos (FP)** - Número de registros da classe 2 incorretamente classificados como classe 1.

Avaliação dos Classificadores

30

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE

REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

Classe 0 : Falha
Classe 1 : Não Falha

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real		
Classe 1 - Real		

Avaliação dos Classificadores

31

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real			
Classe 1 - Real			
Total			

Avaliação dos Classificadores

32

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real			3
Classe 1 - Real			
Total			

Avaliação dos Classificadores

33

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1		3
Classe 1 - Real			
Total			

Avaliação dos Classificadores

34

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real			
Total			

Avaliação dos Classificadores

35

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real			
Total			

Avaliação dos Classificadores

36

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE							
REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real			4
Total			

Avaliação dos Classificadores

37

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE

REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real			4
Total			7

Avaliação dos Classificadores

38

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE

REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1		4
Total			7

Avaliação dos Classificadores

39

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE

REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total			7

Avaliação dos Classificadores

40

□ Matriz de Confusão - Exemplo

CONJUNTO DE TESTE

REGISTROS	1	2	3	4	5	6	7
Real	0	0	1	1	1	0	1
Previsto	0	1	1	1	1	1	0

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

Avaliação dos Classificadores

41

□ Matriz de Confusão - Exemplo

	Classe 1 - Previsão	Classe 2 - Previsão
Classe 1 - Real	VP	FN
Classe 2 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

Avaliação dos Classificadores

42

□ Matriz de Confusão - Exemplo

	Classe 1 - Previsão	Classe 2 - Previsão
Classe 1 - Real	VP	FN
Classe 2 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

Avaliação dos Classificadores

43

□ Acurácia

Acurácia (ACC) – Taxa de Classificação correta

$$ACC = \frac{VP+VN}{VP+FP+FN+VN}$$

	Classe 1 - Previsão	Classe 2 - Previsão
Classe 1 - Real	VP	FN
Classe 2 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

$$ACC = \frac{1+3}{1+1+2+3} = \frac{4}{7}$$

$$ACC = 57\%$$

OBS: As estatísticas globais de acurácia NÃO informam sobre o erro que o modelo está realizando para cada classe!

Avaliação dos Classificadores

44

□ Precisão (Sensitividade)

Precisão (PRE) – Calculada para cada classe

$$PRE(C_1) = \frac{VP}{VP+FP} ; PRE(C_2) = \frac{VN}{VN+FN}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7



$$PRE(C_0) = \frac{1}{1+1} = \frac{1}{2}$$

Avaliação dos Classificadores

45

□ Precisão (Sensitividade)

Precisão (PRE) – Calculada para cada classe

$$PRE(C_1) = \frac{VP}{VP+FP} ; PRE(C_2) = \frac{VN}{VN+FN}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

↓

$$PRE(C_1) = \frac{3}{3+2} = \frac{3}{5}$$

Avaliação dos Classificadores

46

□ Precisão (Sensitividade)

Precisão (PRE) – Calculada para cada classe

$$PRE(C_1) = \frac{VP}{VP+FP} ; PRE(C_2) = \frac{VN}{VN+FN}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

$$PRE(C_0) = 50\% \quad PRE(C_1) = 60\%$$

Precisão mede a capacidade de
predição do modelo!

Avaliação dos Classificadores

47

□ Recuperação/ Recall (REC)

Recuperação/ Recall (REC) – Calculada para cada classe

$$REC(C_1) = \frac{VP}{VP + FN} ; REC(C_2) = \frac{VN}{VN + FP}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

$$REC(C_0) = \frac{1}{1 + 2} = \frac{1}{3}$$

Avaliação dos Classificadores

48

□ Recuperação/ Recall (REC)

Recuperação/ Recall (REC) – Calculada para cada classe

$$REC(C_1) = \frac{VP}{VP + FN} ; REC(C_2) = \frac{VN}{VN + FP}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

$$REC(C_1) = \frac{3}{3 + 1} = \frac{3}{4}$$

Avaliação dos Classificadores

49

□ Recuperação/ Recall (REC)

Recuperação/ Recall (REC) – Calculada para cada classe

$$REC(C_1) = \frac{VP}{VP + FN} ; REC(C_2) = \frac{VN}{VN + FP}$$

	Classe 0 - Previsão	Classe 1 - Previsão
Classe 0 - Real	VP	FN
Classe 1 - Real	FP	VN

CONJUNTO DE TESTE

	Classe 0 - Previsão	Classe 1 - Previsão	Total
Classe 0 - Real	1	2	3
Classe 1 - Real	1	3	4
Total	2	5	7

$$REC(C_0) = 33\% \quad REC(C_1) = 75\%$$

Recuperação é a capacidade
de reconhecer os registros da
classe correspondente

Avaliação dos Classificadores

50

□ Classes Desbalanceadas:

Característico de Problemas de Doenças:

	Doente - Previsão	Não Doente - Previsão	Total
Doente - Real	0	2	2
Não Doente - Real	0	98	98
Total	0	100	100

$$ACC = \frac{98}{100} = 98\%$$

- $PRE(Doente) = 0$
- $PRE(Não\ doente) = 0,98$
- $Recal(Doente) = \frac{0}{2} = 0$
- $Recal(Não\ Doente) = \frac{98}{98} = 1$

Referências Bibliográficas

51

- Evsukoff, A G. **INTELIGÊNCIA COMPUTACIONAL Fundamentos e aplicações**. 2020.
- Grus, J. **Data Science from Scratch. First Principles with Python**. 2015
- Muller, A and Guido, S. **Introduction to Machine Learning with Python. A guide for Data Scientists**. 2016.
- VanderPlas, J. **Python Data Science Handbook**. 2016.